

Evaluación y Comparación de Modelos Regularizados para Scoring Crediticio

Curso: Machine Learning – Módulo 5

Elaborado por Mary Huaiquin en el marco del curso de Machine Learning de Talento Digital dictado por Kibernetum Capacitación.

1. Introducción

El presente informe detalla el desarrollo de un modelo de scoring crediticio basado en técnicas de regularización aplicadas a la regresión logística. Se comparan los modelos Lasso (L1) y Ridge (L2) utilizando el dataset público “credit-g” de OpenML, con el objetivo de predecir la probabilidad de incumplimiento crediticio a partir de variables socioeconómicas y financieras. Este análisis forma parte de la Evaluación Modular 11 del curso de Machine Learning.

2. Descripción del dataset

El dataset 'credit-g' contiene información de 1000 solicitantes de crédito en un banco alemán. Cada observación incluye 20 variables predictoras, tanto numéricas como categóricas, y una variable objetivo que indica el nivel de riesgo (bueno o malo).

Principales variables predictoras consideradas:

- checking_status: estado de la cuenta corriente.
- credit_history: historial crediticio.
- savings_status: nivel de ahorro.
- purpose: propósito del crédito.
- foreign_worker: condición de trabajador extranjero.

El preprocesamiento incluyó imputación de valores faltantes, codificación categórica mediante OneHotEncoder, escalado de variables numéricas y división del dataset en conjuntos de entrenamiento (80%) y prueba (20%).

3. Metodología

Se aplicaron dos variantes de la regresión logística: Lasso (penalización L1) y Ridge (penalización L2). Ambas técnicas permiten controlar la complejidad del modelo y evitar el sobreajuste penalizando los coeficientes.

El modelo Lasso tiende a eliminar variables menos relevantes, generando soluciones más simples e interpretables, mientras que Ridge conserva todas las variables pero reduce sus magnitudes, ofreciendo mayor estabilidad frente a la colinealidad.

4. Resultados de evaluación

Las métricas de evaluación obtenidas fueron las siguientes:

Métrica	Accuracy	Precision (Clase 1)	Recall (Clase 1)	F1-Score (Clase 1)	AUC
Lasso	0.78	0.67	0.53	0.59	0.8127
Ridge	0.78	0.67	0.53	0.59	0.8055

Ambos modelos presentan un rendimiento similar, con una ligera ventaja del modelo Lasso en el AUC, lo cual indica una mejor capacidad discriminativa. Los resultados sugieren que ambos modelos clasifican correctamente 78% de los casos, con un balance adecuado entre precisión y recall.

5. Interpretación de resultados

El análisis de los coeficientes mostró que el modelo Lasso eliminó algunas variables irrelevantes, mientras que Ridge las mantuvo con valores reducidos. Esto resalta la utilidad de Lasso cuando se busca un modelo más simple y explicativo.

Las variables más influyentes fueron:

- checking_status_no checking → alto riesgo de incumplimiento.
- credit_history_critical/other → historial crediticio crítico.
- purpose_education → créditos menos seguros.
- foreign_worker_yes → mayor riesgo asociado.
- savings_status_>=1000 → factor protector frente al incumplimiento.

El análisis de la curva ROC mostró un área bajo la curva superior a 0.80 para ambos modelos, indicando una buena capacidad predictiva. La matriz de confusión reflejó un equilibrio aceptable entre falsos positivos y negativos.

6. Comparación de Lasso y Ridge

Ambos métodos de regularización logran resultados muy cercanos en desempeño global, pero difieren en su interpretabilidad y estructura interna. Lasso proporciona modelos más simples al forzar coeficientes a cero, mientras que Ridge produce soluciones más estables y menos sensibles a cambios en los datos.

Criterio	Lasso (L1)	Ridge (L2)
Tipo de regularización	Penaliza la suma de los valores absolutos (L1)	Penaliza la suma de los cuadrados (L2)
Efecto en los coeficientes	Elimina variables irrelevantes	Reduce magnitudes pero mantiene todas las variables
Interpretabilidad	Alta, facilita explicación del modelo	Moderada, conserva información completa
Rendimiento	Ligeramente superior en AUC	Rendimiento estable y consistente

7. Reflexión personal y aprendizajes

El desarrollo de este proyecto permitió afianzar conocimientos sobre regularización y evaluación de modelos de clasificación. Se comprendió cómo la elección entre Lasso y Ridge depende del equilibrio entre rendimiento y explicabilidad. En contextos financieros, donde las decisiones deben ser transparentes y auditables, un modelo interpretable es preferible a uno ligeramente más preciso.

Además, se reforzó la importancia del preprocesamiento y la validación cruzada como pasos esenciales para garantizar resultados confiables. Este proyecto demostró cómo la regularización ayuda a prevenir el sobreajuste y mejora la generalización del modelo.

8. Conclusión final

En conclusión, tanto Lasso como Ridge resultan apropiados para tareas de scoring crediticio. Lasso destacó por su mayor interpretabilidad, mientras que Ridge ofreció mayor robustez. Ambos modelos lograron un AUC superior a 0.80, considerado un buen nivel de discriminación en clasificación binaria. Este trabajo permitió conectar la teoría de la regularización con un caso práctico de análisis de riesgo crediticio, aplicando correctamente métricas, preprocesamiento y comparación de modelos.